

Calories Prediction — Data Exploration

استكشاف بيانات التنبؤ بالسعرات الحرارية

This notebook performs the first exploration of the Running Calorie Burn Dataset.

يهدف هذا الدفتر إلى إجراء الاستكشاف الأولي لبيانات حرق السعرات أثناء الجري.

Objectives | الأهداف

- Load the raw dataset. — تحميل البيانات الأصلية.
- Understand the dataset structure. — فهم هيكل البيانات.
- Check missing values and duplicates. — فحص القيم المفقودة والتكرارات.
- Identify numerical and categorical features. — تحديد المتغيرات الرقمية والفئوية.
- Explore the target variable. — استكشاف المتغير المستهدف.
- Prepare the data for further analysis. — تجهيز البيانات للتحليل القادم.

1. Import Required Libraries

استيراد المكتبات المطلوبة

We use the reusable functions created inside the `src` package.

حتى يبقى المشروع منظمًا وقابلًا لإعادة `src` نستخدم الدوال الجاهزة التي أنشأناها داخل مجلد الاستخدام.

```
In [1]: import sys
from pathlib import Path

# Add project root to Python path
PROJECT_ROOT = Path.cwd().resolve()

if PROJECT_ROOT.name == "notebooks":
    PROJECT_ROOT = PROJECT_ROOT.parent

if str(PROJECT_ROOT) not in sys.path:
    sys.path.append(str(PROJECT_ROOT))

from src.data_loader import load_raw_data, get_dataset_info

from src.data_analysis import (
    get_missing_values,
    get_duplicates,
```

```

get_numerical_columns,
get_categorical_columns,
get_statistics,
get_unique_values,
get_categorical_summary,
analyze_target,
get_outlier_summary,
)

print(f"Project root: {PROJECT_ROOT}")

```

Project root: C:\Users\ayman\OneDrive\Desktop\calories-prediction

2. Load the Dataset

تحميل البيانات

The raw dataset is stored in `data/raw/dataset.csv`.

يتم تخزين البيانات الأصلية داخل `data/raw/dataset.csv`.

```

In [2]: df = load_raw_data()

print("Dataset loaded successfully!")
print("تم تحميل البيانات بنجاح!")

df.head()

```

Dataset loaded successfully!
تم تحميل البيانات بنجاح!

```

Out[2]:

```

	Gender	Age	Height(cm)	Weight(kg)	BMI	Running Time(min)	Running Speed(km/h)	Distance(km)	At
0	Male	49	184	74	20.4	78	9.5	3.00	
1	Female	56	182	70	23.2	98	10.2	5.23	
2	Male	49	170	85	27.4	91	10.4	7.61	
3	Male	21	181	59	24.0	89	13.4	14.19	
4	Male	47	172	86	29.8	79	9.8	3.84	

3. Dataset Shape

حجم مجموعة البيانات

The shape shows the number of observations and columns.

عدد السجلات وعدد الأعمدة الموجودة في البيانات Shape يوضح الـ

```
In [3]: rows, columns = df.shape

print(f"Rows      : {rows}")
print(f"Columns   : {columns}")

print(f"عدد الصفوف      : {rows}")
print(f"عدد الأعمدة      : {columns}")
```

```
Rows      : 200
Columns   : 10
200 :      عدد الصفوف
10  :      عدد الأعمدة
```

4. Dataset Information

معلومات مجموعة البيانات

Here we collect the main structural information about the dataset.

هنا نجمع المعلومات الأساسية المتعلقة بهيكل مجموعة البيانات.

```
In [4]: dataset_info = get_dataset_info(df)

for key, value in dataset_info.items():
    print(f"{key}: {value}")
```

```
rows: 200
columns: 10
total_values: 2000
column_names: ['Gender', 'Age', 'Height(cm)', 'Weight(kg)', 'BMI', 'Running Time(mi
n)', 'Running Speed(km/h)', 'Distance(km)', 'Average Heart Rate', 'Calories Burned']
missing_values: 0
duplicate_rows: 0
```

5. Column Names

أسماء الأعمدة

These columns describe the person's characteristics and running activity.

تمثل هذه الأعمدة خصائص الشخص وبيانات نشاط الجري.

```
In [5]: for index, column in enumerate(df.columns, start=1):
        print(f"{index}. {column}")
```

1. Gender
2. Age
3. Height(cm)
4. Weight(kg)
5. BMI
6. Running Time(min)
7. Running Speed(km/h)
8. Distance(km)
9. Average Heart Rate
10. Calories Burned

6. Data Types

أنواع البيانات

Checking data types helps us distinguish numerical features from categorical features.

يساعدنا فحص أنواع البيانات على التمييز بين المتغيرات الرقمية والمتغيرات الفئوية.

```
In [6]: df.dtypes
```

```
Out[6]: Gender          str
Age          int64
Height(cm)   int64
Weight(kg)   int64
BMI          float64
Running Time(min)  int64
Running Speed(km/h) float64
Distance(km)   float64
Average Heart Rate  int64
Calories Burned  int64
dtype: object
```

7. First and Last Records

أول وآخر سجلات

We inspect the first and last records to understand the structure and values.

نستعرض أول وآخر سجلات لفهم شكل البيانات والقيم الموجودة فيها.

```
In [7]: print("First 5 rows | أول 5 صفوف:")
display(df.head())

print("Last 5 rows | آخر 5 صفوف:")
display(df.tail())
```

First 5 rows | أول 5 صفوف:

	Gender	Age	Height(cm)	Weight(kg)	BMI	Running Time(min)	Running Speed(km/h)	Distance(km)	Ave H
0	Male	49	184	74	20.4	78	9.5	3.00	
1	Female	56	182	70	23.2	98	10.2	5.23	
2	Male	49	170	85	27.4	91	10.4	7.61	
3	Male	21	181	59	24.0	89	13.4	14.19	
4	Male	47	172	86	29.8	79	9.8	3.84	

◀ ▶
Last 5 rows | آخر 5 صفوف :

	Gender	Age	Height(cm)	Weight(kg)	BMI	Running Time(min)	Running Speed(km/h)	Distance(km)	A
195	Female	54	199	51	18.5	92	10.4	3.21	
196	Female	41	194	59	19.8	90	14.0	12.56	
197	Female	46	160	79	23.9	78	10.3	6.53	
198	Male	63	178	99	25.5	100	10.7	13.94	
199	Male	48	185	94	27.6	30	14.9	14.61	

◀ ▶

8. Missing Values

القيم المفقودة

Missing values can affect statistical analysis and machine learning models.

القيم المفقودة يمكن أن تؤثر على التحليل الإحصائي ونماذج التعلم الآلي.

```
In [8]: missing_values = get_missing_values(df)

if missing_values.empty:
    print("No missing values found.")
    print("لم يتم العثور على قيم مفقودة.")
else:
    display(missing_values.to_frame(name="Missing Values"))
```

No missing values found.
لم يتم العثور على قيم مفقودة.

9. Duplicate Rows

الصفوف المكررة

Duplicate observations can affect the quality of analysis and model training.

السجلات المكررة يمكن أن تؤثر على جودة التحليل وتدريب النموذج.

```
In [9]: duplicates = get_duplicates(df)

print(f"Duplicate rows: {duplicates}")
print(f"الصفوف المكررة: {duplicates}")
```

```
Duplicate rows: 0
الصفوف المكررة: 0
```

10. Numerical Columns

الأعمدة الرقمية

Numerical columns contain measurements that can be used in statistical analysis and machine learning.

الأعمدة الرقمية تحتوي على قياسات يمكن استخدامها في التحليل الإحصائي والتعلم الآلي.

```
In [10]: numerical_columns = get_numerical_columns(df)

print(f"Number of numerical columns: {len(numerical_columns)}")
print(f"عدد الأعمدة الرقمية: {len(numerical_columns)}")

for column in numerical_columns:
    print(f"- {column}")
```

```
Number of numerical columns: 9
عدد الأعمدة الرقمية: 9
- Age
- Height(cm)
- Weight(kg)
- BMI
- Running Time(min)
- Running Speed(km/h)
- Distance(km)
- Average Heart Rate
- Calories Burned
```

11. Categorical Columns

الأعمدة الفئوية

Categorical columns contain labels or groups rather than continuous numerical measurements.

الأعمدة الفئوية تحتوي على تصنيفات أو مجموعات بدلاً من القياسات الرقمية المستمرة.

```
In [11]: categorical_columns = get_categorical_columns(df)

print(f"Number of categorical columns: {len(categorical_columns)}")
print(f"عدد الأعمدة الفئوية: {len(categorical_columns)}")

for column in categorical_columns:
    print(f"- {column}")
```

Number of categorical columns: 1
عدد الأعمدة الفئوية: 1
- Gender

12. Unique Values

القيم الفريدة

This gives us an initial idea about the variety of values in each column.

تعطينا هذه الخطوة فكرة أولية عن تنوع القيم في كل عمود.

```
In [12]: unique_values = get_unique_values(df)

display(
    unique_values.to_frame(name="Unique Values")
)
```

Unique Values	
Distance(km)	186
Calories Burned	180
BMI	96
Running Time(min)	80
Running Speed(km/h)	73
Average Heart Rate	56
Height(cm)	49
Weight(kg)	49
Age	46
Gender	2

13. Categorical Summary

ملخص الأعمدة الفئوية

For each categorical feature, we inspect the number of categories and the most common category.

لكل متغير فئوي، نستعرض عدد الفئات والقيمة الأكثر تكرارًا.

```
In [13]: categorical_summary = get_categorical_summary(df)

if categorical_summary.empty:
    print("No categorical columns found.")
    print("لم يتم العثور على أعمدة فئوية.")
else:
    display(categorical_summary)
```

	column	unique_values	most_common	most_common_count
0	Gender	2	Female	100

14. Gender Distribution

توزيع الجنس

The `Gender` column is categorical, so we inspect the number of records in each category.

متغير فئوي، لذلك نتحقق من عدد السجلات في كل فئة `Gender` عمود.

```
In [14]: if "Gender" in df.columns:
    gender_counts = df["Gender"].value_counts()
    display(gender_counts.to_frame(name="Count"))
else:
    print("Gender column not found.")
```

Count	
Gender	
Male	100
Female	100

15. Statistical Summary

الملخص الإحصائي

We calculate mean, median, mode, minimum, maximum, range, standard deviation, variance, quartiles, and percentiles.

نحسب المتوسط والوسيط والمنوال والقيمة الدنيا والعليا والمدى والانحراف المعياري والتباين والربيعات والنسب المئوية.

```
In [15]: statistics = get_statistics(df)

display(statistics)
```

	count	mean	median	mode	min	max	range	std	variance
Age	200	41.38500	44.000	50.00	18.0	64.00	46.00	13.225785	174.921
Height(cm)	200	175.09500	175.000	175.00	150.0	199.00	49.00	14.266170	203.523
Weight(kg)	200	75.18500	74.500	77.00	50.0	99.00	49.00	14.106585	198.995
BMI	200	24.24400	24.600	19.50	18.5	30.00	11.50	3.243558	10.520
Running Time(min)	200	74.34000	74.500	58.00	30.0	119.00	89.00	25.028916	626.446
Running Speed(km/h)	200	11.34150	11.350	11.20	7.0	15.00	8.00	2.167769	4.699
Distance(km)	200	8.92655	8.825	13.23	3.0	14.96	11.96	3.819304	14.587
Average Heart Rate	200	149.82000	150.500	139.00	121.0	179.00	58.00	16.949158	287.273
Calories Burned	200	584.08500	554.000	200.00	200.0	996.00	796.00	228.289659	52116.166

16. Target Variable — Calories Burned

المتغير المستهدف — السعرات الحرارية المحروقة

The target variable for this regression project is **Calories Burned**.

المتغير المستهدف في مشروع الانحدار هذا هو **Calories Burned**.

The goal of the machine learning model will be to predict this value using the available features.

هدف نموذج التعلم الآلي لاحقًا هو التنبؤ بهذه القيمة اعتمادًا على الخصائص المتوفرة.

```
In [16]: target_analysis = analyze_target(
df,
"Calories Burned"
)

display(
```

```
target_analysis.to_frame(name="Value")
)
```

	Value
count	200.000000
mean	584.085000
median	554.000000
mode	200.000000
min	200.000000
max	996.000000
range	796.000000
std	228.289659
variance	52116.168618
Q1	395.750000
Q2	554.000000
Q3	791.500000
IQR	395.750000

17. Outlier Check

فحص القيم الشاذة

We use the IQR method to identify possible statistical outliers.

لتحديد القيم التي قد تعتبر شاذة إحصائيًا IQR نستخدم طريقة

An outlier is not automatically an incorrect value. It should be investigated before deciding whether to remove it.

وجود قيمة شاذة إحصائيًا لا يعني بالضرورة أنها قيمة خاطئة، لذلك يجب فحصها قبل حذفها.

```
In [17]: outlier_summary = get_outlier_summary(df)

display(
    outlier_summary.to_frame(name="Outlier Count")
)
```

Outlier Count	
Age	0
Height(cm)	0
Weight(kg)	0
BMI	0
Running Time(min)	0
Running Speed(km/h)	0
Distance(km)	0
Average Heart Rate	0
Calories Burned	0

18. Dataset Preview

معاينة البيانات

Here we display ten records together with all available columns.

هنا نستعرض عشرة سجلات مع جميع الأعمدة المتوفرة لفهم البيانات بشكل سريع.

```
In [18]: display(df.head(10))
```

	Gender	Age	Height(cm)	Weight(kg)	BMI	Running Time(min)	Running Speed(km/h)	Distance(km)	Ave H
0	Male	49	184	74	20.4	78	9.5	3.00	
1	Female	56	182	70	23.2	98	10.2	5.23	
2	Male	49	170	85	27.4	91	10.4	7.61	
3	Male	21	181	59	24.0	89	13.4	14.19	
4	Male	47	172	86	29.8	79	9.8	3.84	
5	Female	54	182	58	22.8	107	10.7	3.11	
6	Male	40	152	73	27.1	104	12.0	3.63	
7	Male	56	167	84	23.0	38	10.0	4.06	
8	Male	62	174	98	28.0	63	13.7	3.45	
9	Female	32	191	84	25.0	105	11.7	8.76	

19. Basic Checks

الفحوصات الأساسية

These assertions make sure that the dataset is loaded correctly and contains the expected target column.

تأكد لنا هذه الفحوصات أن البيانات تم تحميلها بشكل صحيح وأن المتغير المستهدف موجود.

```
In [19]: assert len(df) > 0
assert "Calories Burned" in df.columns
assert df.isnull().sum().sum() == 0

print("All basic exploration checks passed!")
print("جميع فحوصات الاستكشاف الأساسية نجحت")
```

All basic exploration checks passed!
جميع فحوصات الاستكشاف الأساسية نجحت

20. Initial Findings

النتائج الأولية

Based on this first exploration:

بناءً على هذا الاستكشاف الأولي:

- The dataset contains 200 observations and 10 columns. تحتوي مجموعة البيانات على 200 سجل و10 أعمدة.
- **Gender** is a categorical feature. **Gender** متغير فئوي.
- The remaining measured features are numerical. باقي الخصائص المقاسة هي متغيرات رقمية.
- **Calories Burned** is the target variable. **Calories Burned** هو المتغير المستهدف.
- There are currently no missing values. لا توجد حاليًا قيم مفقودة.
- There are currently no duplicate rows. لا توجد حاليًا صفوف مكررة.
- The current IQR check does not identify numerical outliers. الحالي لم يحدد قيمًا IQR فحص شاذة في الأعمدة الرقمية.

الخطوة القادمة | Next Step

The next notebook will focus on deeper data analysis and visualization.

سيركز الدفتر القادم على التحليل الأعمق للبيانات والتصورات البصرية والعلاقات بين المتغيرات.