

Calories Prediction — Advanced Data Exploration

استكشاف وتحليل البيانات بشكل متقدم

This notebook continues the initial exploration of the Running Calorie Burn Dataset.

يأتي هذا الدفتر كتكملة للاستكشاف الأولي لبيانات حرق السعرات أثناء الجري.

The main goal is to understand relationships between variables and investigate the target variable before machine learning.

الهدف الرئيسي هو فهم العلاقات بين المتغيرات ودراسة المتغير المستهدف قبل الانتقال إلى مرحلة التعلم الآلي.

Objectives | الأهداف

- Analyze numerical variables. — تحليل المتغيرات الرقمية.
- Analyze categorical variables. — تحليل المتغيرات الفئوية.
- Study correlations between numerical features. — دراسة الارتباطات بين المتغيرات الرقمية.
- Analyze correlations with the target. — تحليل الارتباط مع المتغير المستهدف.
- Study the distribution of `Calories Burned`. — دراسة توزيع `Calories Burned`.
- Compare calories burned by gender. — مقارنة السعرات المحروقة حسب الجنس.
- Investigate relationships between running features and calories. — دراسة العلاقات بين خصائص الجري والسعرات.
- Prepare observations for the machine learning stage. — تجهيز الملاحظات لمرحلة التعلم الآلي.

1. Import Libraries

استيراد المكتبات

We import the dataset loader, analysis functions, and visualization libraries.

نستورد أدوات تحميل البيانات ودوال التحليل ومكتبات التصور البياني.

```
In [1]: import sys
from pathlib import Path

import pandas as pd
import numpy as np
```

```

# Add project root to Python path
PROJECT_ROOT = Path.cwd().resolve()

if PROJECT_ROOT.name == "notebooks":
    PROJECT_ROOT = PROJECT_ROOT.parent

if str(PROJECT_ROOT) not in sys.path:
    sys.path.append(str(PROJECT_ROOT))

from src.data_loader import load_raw_data

from src.data_analysis import (
    get_numerical_columns,
    get_categorical_columns,
    get_statistics,
    get_correlation,
    analyze_target,
    get_outlier_summary,
)

print("Libraries imported successfully!")
print("تم استيراد المكتبات بنجاح")

```

Libraries imported successfully!
تم استيراد المكتبات بنجاح

2. Load Dataset

تحميل البيانات

We load the original dataset from the project's raw data directory.

نقوم بتحميل مجموعة البيانات الأصلية من مجلد البيانات الخام في المشروع.

```

In [2]: df = load_raw_data()

print(f"Dataset shape: {df.shape}")
print(f"حجم البيانات: {df.shape}")

display(df.head())

```

Dataset shape: (200, 10)
حجم البيانات: (200, 10)

	Gender	Age	Height(cm)	Weight(kg)	BMI	Running Time(min)	Running Speed(km/h)	Distance(km)	Ave H
0	Male	49	184	74	20.4	78	9.5	3.00	
1	Female	56	182	70	23.2	98	10.2	5.23	
2	Male	49	170	85	27.4	91	10.4	7.61	
3	Male	21	181	59	24.0	89	13.4	14.19	
4	Male	47	172	86	29.8	79	9.8	3.84	

3. Numerical Features

المتغيرات الرقمية

We identify the numerical variables that can be analyzed statistically.

نحدد المتغيرات الرقمية التي يمكن تحليلها إحصائيًا.

```
In [3]: numerical_columns = get_numerical_columns(df)

print("Numerical features | المتغيرات الرقمية:")

for column in numerical_columns:
    print(f"- {column}")
```

Numerical features | المتغيرات الرقمية:

- Age
- Height(cm)
- Weight(kg)
- BMI
- Running Time(min)
- Running Speed(km/h)
- Distance(km)
- Average Heart Rate
- Calories Burned

4. Categorical Features

المتغيرات الفئوية

Categorical features represent groups or categories.

المتغيرات الفئوية تمثل مجموعات أو تصنيفات.

```
In [4]: categorical_columns = get_categorical_columns(df)

print("Categorical features | المتغيرات الفئوية:")

for column in categorical_columns:
    print(f"- {column}")
```

Categorical features | المتغيرات الفئوية:
- Gender

5. Descriptive Statistics

الإحصاءات الوصفية

Descriptive statistics help us understand the central tendency and spread of numerical variables.

تساعدنا الإحصاءات الوصفية على فهم القيم المركزية ومدى انتشار المتغيرات الرقمية.

```
In [5]: statistics = get_statistics(df)

display(statistics)
```

	count	mean	median	mode	min	max	range	std	variance
Age	200	41.38500	44.000	50.00	18.0	64.00	46.00	13.225785	174.921
Height(cm)	200	175.09500	175.000	175.00	150.0	199.00	49.00	14.266170	203.523
Weight(kg)	200	75.18500	74.500	77.00	50.0	99.00	49.00	14.106585	198.995
BMI	200	24.24400	24.600	19.50	18.5	30.00	11.50	3.243558	10.520
Running Time(min)	200	74.34000	74.500	58.00	30.0	119.00	89.00	25.028916	626.446
Running Speed(km/h)	200	11.34150	11.350	11.20	7.0	15.00	8.00	2.167769	4.699
Distance(km)	200	8.92655	8.825	13.23	3.0	14.96	11.96	3.819304	14.587
Average Heart Rate	200	149.82000	150.500	139.00	121.0	179.00	58.00	16.949158	287.273
Calories Burned	200	584.08500	554.000	200.00	200.0	996.00	796.00	228.289659	52116.168

6. Numerical Features Summary

ملخص المتغيرات الرقمية

The table below provides a compact summary of the numerical features.

يعرض الجدول التالي ملخصًا للمتغيرات الرقمية الموجودة في البيانات.

```
In [6]: summary = df[numerical_columns].describe().T

summary["range"] = summary["max"] - summary["min"]

display(summary)
```

	count	mean	std	min	25%	50%	75%	max	range
Age	200.0	41.38500	13.225785	18.0	30.00	44.000	52.0000	64.00	46.00
Height(cm)	200.0	175.09500	14.266170	150.0	163.75	175.000	186.0000	199.00	49.00
Weight(kg)	200.0	75.18500	14.106585	50.0	62.00	74.500	87.0000	99.00	49.00
BMI	200.0	24.24400	3.243558	18.5	21.55	24.600	27.0000	30.00	11.50
Running Time(min)	200.0	74.34000	25.028916	30.0	55.00	74.500	95.0000	119.00	89.00
Running Speed(km/h)	200.0	11.34150	2.167769	7.0	9.80	11.350	13.1250	15.00	8.00
Distance(km)	200.0	8.92655	3.819304	3.0	5.38	8.825	12.6625	14.96	11.96
Average Heart Rate	200.0	149.82000	16.949158	121.0	135.00	150.500	164.2500	179.00	58.00
Calories Burned	200.0	584.08500	228.289659	200.0	395.75	554.000	791.5000	996.00	796.00

7. Correlation Matrix

مصفوفة الارتباط

Correlation measures the strength and direction of a linear relationship between numerical variables.

يقيس الارتباط قوة واتجاه العلاقة الخطية بين المتغيرات الرقمية.

Values close to +1 indicate a strong positive linear relationship, while values close to -1 indicate a strong negative relationship. Values close to 0 indicate a weak linear relationship.

القيم القريبة من +1 تشير إلى علاقة خطية موجبة قوية، والقيم القريبة من -1 تشير إلى علاقة سالبة قوية، بينما القيم القريبة من 0 تشير إلى علاقة خطية ضعيفة.

```
In [7]: correlation = get_correlation(df)
```

```
display(correlation)
```

	Age	Height(cm)	Weight(kg)	BMI	Running Time(min)	Running Speed(km/h)	Distance(km)
Age	1.000000	-0.115622	-0.062736	-0.036499	0.008984	-0.113733	-0.020051
Height(cm)	-0.115622	1.000000	-0.030276	-0.115931	0.112313	-0.028401	0.067200
Weight(kg)	-0.062736	-0.030276	1.000000	-0.050567	-0.109841	0.061732	0.018295
BMI	-0.036499	-0.115931	-0.050567	1.000000	-0.039732	-0.106841	0.144888
Running Time(min)	0.008984	0.112313	-0.109841	-0.039732	1.000000	-0.061102	-0.056769
Running Speed(km/h)	-0.113733	-0.028401	0.061732	-0.106841	-0.061102	1.000000	0.008205
Distance(km)	-0.020051	0.067200	0.018295	0.144888	-0.056769	0.008205	1.000000
Average Heart Rate	-0.115899	0.062085	0.017206	-0.046920	-0.035617	-0.010710	0.000000
Calories Burned	0.035348	0.100808	0.070512	-0.059128	-0.056699	0.013207	-0.000000

8. Correlation with Target

الارتباط مع المتغير المستهدف

Here we calculate how each numerical feature is linearly correlated with **Calories Burned**.

هنا نحسب مدى ارتباط كل متغير رقمي خطيًا مع **Calories Burned**.

```
In [8]: target_column = "Calories Burned"

target_correlations = (
    correlation[target_column]
    .drop(target_column)
    .sort_values(ascending=False)
)

display(
    target_correlations.to_frame(name="Correlation")
)
```

	Correlation
Height(cm)	0.100808
Weight(kg)	0.070512
Age	0.035348
Average Heart Rate	0.014701
Running Speed(km/h)	0.013207
Distance(km)	-0.051363
Running Time(min)	-0.056699
BMI	-0.059128

التفسير | Interpretation

Correlation only measures linear relationships. A low correlation does not necessarily mean that a feature has no predictive value because the relationship may be nonlinear or involve interactions with other variables.

الارتباط يقيس العلاقات الخطية فقط. لذلك فإن الارتباط المنخفض لا يعني بالضرورة أن المتغير غير مفيد للتنبؤ، فقد تكون العلاقة غير خطية أو تعتمد على تفاعل المتغير مع متغيرات أخرى.

9. Absolute Target Correlations

قوة الارتباط مع المتغير المستهدف

We sort features by the absolute value of their correlation with the target.

نرتب المتغيرات حسب القيمة المطلقة للارتباط مع المتغير المستهدف، حتى نعرف قوة العلاقة بغض النظر عن اتجاهها.

```
In [9]: absolute_target_correlations = (
        target_correlations.abs()
        .sort_values(ascending=False)
    )

display(
    absolute_target_correlations.to_frame(
        name="Absolute Correlation"
    )
)
```

Absolute Correlation	
Height(cm)	0.100808
Weight(kg)	0.070512
BMI	0.059128
Running Time(min)	0.056699
Distance(km)	0.051363
Age	0.035348
Average Heart Rate	0.014701
Running Speed(km/h)	0.013207

10. Target Variable Statistics

إحصاءات المتغير المستهدف

The target variable is `Calories Burned`. We examine its distribution numerically before building a regression model.

نقوم بدراسة توزيعه رقميًا قبل بناء نموذج الانحدار. `Calories Burned` المتغير المستهدف هو

```
In [10]: target_analysis = analyze_target(
    df,
    target_column
)

display(
    target_analysis.to_frame(name="Value")
)
```

	Value
count	200.000000
mean	584.085000
median	554.000000
mode	200.000000
min	200.000000
max	996.000000
range	796.000000
std	228.289659
variance	52116.168618
Q1	395.750000
Q2	554.000000
Q3	791.500000
IQR	395.750000

11. Target Distribution

توزيع المتغير المستهدف

We inspect the minimum, maximum, mean, and median of calories burned.

نستعرض الحد الأدنى والأقصى والمتوسط والوسيط للسعرات المحروقة.

```
In [11]: target = df[target_column]

print(f"Minimum : {target.min():.2f}")
print(f"Maximum : {target.max():.2f}")
print(f"Mean      : {target.mean():.2f}")
print(f"Median    : {target.median():.2f}")
print(f"Std       : {target.std():.2f}")
```

```
Minimum : 200.00
Maximum : 996.00
Mean     : 584.09
Median   : 554.00
Std      : 228.29
```

12. Target Quantiles

النسب المئوية للمتغير المستهدف

Quantiles help us understand how the target values are distributed across the dataset.

تساعدنا النسب المئوية على فهم كيفية توزيع قيم المتغير المستهدف داخل البيانات.

```
In [12]: quantiles = target.quantile([
    0.01,
    0.05,
    0.10,
    0.25,
    0.50,
    0.75,
    0.90,
    0.95,
    0.99
])

quantiles.index = [
    "1%",
    "5%",
    "10%",
    "25%",
    "50%",
    "75%",
    "90%",
    "95%",
    "99%"
]

display(quantiles.to_frame(name="Calories Burned"))
```

Calories Burned	
1%	200.99
5%	226.65
10%	284.80
25%	395.75
50%	554.00
75%	791.50
90%	903.30
95%	954.10
99%	993.03

13. Gender Analysis

تحليل الجنس

We compare the number of observations and calorie statistics between gender categories.

نقارن عدد السجلات وإحصاءات السعرات الحرارية بين فئات الجنس.

```
In [13]: if "Gender" in df.columns:
gender_summary = (
    df.groupby("Gender")[target_column]
    .agg([
        "count",
        "mean",
        "median",
        "min",
        "max",
        "std"
    ])
    .round(2)
)

display(gender_summary)
else:
    print("Gender column not found.")
```

	count	mean	median	min	max	std
Gender						
Female	100	562.36	506.0	200	996	228.99
Male	100	605.81	568.0	200	996	226.65

14. Running Activity Summary

ملخص نشاط الجري

The following variables describe the running activity:

المتغيرات التالية تصف نشاط الجري:

- Running Time(min) — مدة الجري بالدقائق
- Running Speed(km/h) — سرعة الجري بالكيلومتر/ساعة
- Distance(km) — المسافة بالكيلومتر
- Average Heart Rate — متوسط معدل ضربات القلب

```
In [14]: activity_columns = [
    "Running Time(min)",
    "Running Speed(km/h)",
    "Distance(km)",
    "Average Heart Rate"
]
```

```
activity_columns = [
    column for column in activity_columns
    if column in df.columns
]

display(df[activity_columns].describe().T)
```

	count	mean	std	min	25%	50%	75%	max
Running Time(min)	200.0	74.34000	25.028916	30.0	55.00	74.500	95.0000	119.00
Running Speed(km/h)	200.0	11.34150	2.167769	7.0	9.80	11.350	13.1250	15.00
Distance(km)	200.0	8.92655	3.819304	3.0	5.38	8.825	12.6625	14.96
Average Heart Rate	200.0	149.82000	16.949158	121.0	135.00	150.500	164.2500	179.00

15. Body Measurements Summary

ملخص قياسات الجسم

We also examine age, height, weight, and BMI.

نقوم أيضًا بدراسة العمر والطول والوزن ومؤشر كتلة الجسم.

```
In [15]: body_columns = [
    "Age",
    "Height(cm)",
    "Weight(kg)",
    "BMI"
]

body_columns = [
    column for column in body_columns
    if column in df.columns
]

display(df[body_columns].describe().T)
```

	count	mean	std	min	25%	50%	75%	max
Age	200.0	41.385	13.225785	18.0	30.00	44.0	52.0	64.0
Height(cm)	200.0	175.095	14.266170	150.0	163.75	175.0	186.0	199.0
Weight(kg)	200.0	75.185	14.106585	50.0	62.00	74.5	87.0	99.0
BMI	200.0	24.244	3.243558	18.5	21.55	24.6	27.0	30.0

16. Calories by Running Time

السعرات مقابل مدة الجري

We inspect the average calories burned for different running-time groups.

نستعرض متوسط السعرات المحروقة حسب مجموعات مدة الجري.

```
In [16]: if "Running Time(min)" in df.columns:
         time_groups = pd.qcut(
             df["Running Time(min)"],
             q=4,
             duplicates="drop"
         )

         time_analysis = (
             df.groupby(time_groups, observed=True)[target_column]
               .agg(["count", "mean", "median", "min", "max"])
               .round(2)
         )

         display(time_analysis)
     else:
         print("Running Time column not found.")
```

	count	mean	median	min	max
Running Time(min)					
(29.999, 55.0]	52	626.75	668.0	207	996
(55.0, 74.5]	48	549.54	534.0	200	980
(74.5, 95.0]	51	569.43	540.0	218	996
(95.0, 119.0]	49	587.90	557.0	200	975

17. Calories by Distance

السعرات مقابل المسافة

We divide the distance values into four groups and compare their calorie statistics.

نقسم قيم المسافة إلى أربع مجموعات ونقارن إحصاءات السعرات بينها.

```
In [17]: if "Distance(km)" in df.columns:
         distance_groups = pd.qcut(
             df["Distance(km)"],
             q=4,
```

```

        duplicates="drop"
    )

    distance_analysis = (
        df.groupby(distance_groups, observed=True)[target_column]
        .agg(["count", "mean", "median", "min", "max"])
        .round(2)
    )

    display(distance_analysis)
else:
    print("Distance column not found.")

```

	count	mean	median	min	max
Distance(km)					
(2.999, 5.38]	50	568.04	537.5	211	975
(5.38, 8.825]	50	643.54	679.0	200	996
(8.825, 12.662]	50	561.68	552.0	200	977
(12.662, 14.96]	50	563.08	507.5	207	996

18. Calories by Heart Rate

السعرات مقابل معدل ضربات القلب

We group average heart rate into quartiles and compare calorie statistics.

نقسم متوسط معدل ضربات القلب إلى أربع مجموعات ونقارن إحصاءات السعرات الحرارية.

```

In [18]: if "Average Heart Rate" in df.columns:
    heart_rate_groups = pd.qcut(
        df["Average Heart Rate"],
        q=4,
        duplicates="drop"
    )

    heart_rate_analysis = (
        df.groupby(heart_rate_groups, observed=True)[target_column]
        .agg(["count", "mean", "median", "min", "max"])
        .round(2)
    )

    display(heart_rate_analysis)
else:
    print("Average Heart Rate column not found.")

```

	count	mean	median	min	max
Average Heart Rate					
(120.999, 135.0]	51	598.78	574.0	201	980
(135.0, 150.5]	49	550.18	523.0	200	996
(150.5, 164.25]	50	588.26	555.0	220	996
(164.25, 179.0]	50	598.14	562.0	200	993

19. Calories by Weight

السعرات مقابل الوزن

We group weight values into quartiles and compare the target variable.

نقسم قيم الوزن إلى أربع مجموعات ونقارن المتغير المستهدف بينها.

```
In [19]: if "Weight(kg)" in df.columns:
weight_groups = pd.qcut(
    df["Weight(kg)"],
    q=4,
    duplicates="drop"
)

weight_analysis = (
    df.groupby(weight_groups, observed=True)[target_column]
    .agg(["count", "mean", "median", "min", "max"])
    .round(2)
)

display(weight_analysis)
else:
    print("Weight column not found.")
```

	count	mean	median	min	max
Weight(kg)					
(49.999, 62.0]	51	556.90	543.0	219	996
(62.0, 74.5]	49	584.65	544.0	200	977
(74.5, 87.0]	53	595.38	613.0	200	996
(87.0, 99.0]	47	600.26	560.0	213	993

20. Outlier Summary

ملخص القيم الشاذة

We review the number of possible outliers using the IQR method.

IQR. نراجع عدد القيم التي قد تعتبر شاذة باستخدام طريقة

```
In [20]: outliers = get_outlier_summary(df)

display(
    outliers.to_frame(name="Outlier Count")
)
```

Outlier Count	
Age	0
Height(cm)	0
Weight(kg)	0
BMI	0
Running Time(min)	0
Running Speed(km/h)	0
Distance(km)	0
Average Heart Rate	0
Calories Burned	0

21. Potential Feature Relationships

العلاقات المحتملة بين الخصائص

The main variables related to the running activity are compared with the target conceptually.

نركز هنا على المتغيرات المرتبطة بنشاط الجري ونقارنها بشكل تحليلي مع المتغير المستهدف

Important variables to investigate further include running time, running speed, distance, heart rate, weight, BMI, and gender.

من أهم المتغيرات التي يجب دراستها لاحقًا: مدة الجري، سرعة الجري، المسافة، معدل ضربات القلب، والجنس، BMI، الوزن.

```
In [21]: selected_columns = [
    "Gender",
    "Age",
    "Weight(kg)",
    "BMI",
    "Running Time(min)",
```

```

    "Running Speed(km/h)",
    "Distance(km)",
    "Average Heart Rate",
    "Calories Burned"
]

selected_columns = [
    column for column in selected_columns
    if column in df.columns
]

display(df[selected_columns].head(10))

```

	Gender	Age	Weight(kg)	BMI	Running Time(min)	Running Speed(km/h)	Distance(km)	Average Heart Rate	Calorie Burned
0	Male	49	74	20.4	78	9.5	3.00	139	97
1	Female	56	70	23.2	98	10.2	5.23	165	49
2	Male	49	85	27.4	91	10.4	7.61	134	95
3	Male	21	59	24.0	89	13.4	14.19	144	57
4	Male	47	86	29.8	79	9.8	3.84	149	38
5	Female	54	58	22.8	107	10.7	3.11	133	44
6	Male	40	73	27.1	104	12.0	3.63	126	83
7	Male	56	84	23.0	38	10.0	4.06	136	46
8	Male	62	98	28.0	63	13.7	3.45	163	84
9	Female	32	84	25.0	105	11.7	8.76	139	43

22. Data Quality Check

فحص جودة البيانات

Before moving to visualization and machine learning, we verify that the dataset is complete and structurally valid.

قبل الانتقال إلى التصور البياني والتعلم الآلي، نتحقق من أن البيانات مكتملة وصحيحة من ناحية الهيكل.

```

In [22]: print("Rows", len(df))
print("Columns", len(df.columns))
print("Missing values", df.isnull().sum().sum())
print("Duplicate rows", df.duplicated().sum())
print("Target available", target_column in df.columns)

assert len(df) == 200

```

```
assert len(df.columns) == 10
assert df.isnull().sum().sum() == 0
assert df.duplicated().sum() == 0
assert target_column in df.columns

print("\nData quality checks passed!")
print("نجحت جميع فحوصات جودة البيانات")
```

```
Rows          : 200
Columns       : 10
Missing values : 0
Duplicate rows : 0
Target available : True
```

Data quality checks passed!
!نجحت جميع فحوصات جودة البيانات

23. Analysis Summary

ملخص التحليل

Dataset

- The dataset contains 200 observations and 10 columns. 10 و 200 سجل تحتوي البيانات على 10 أعمدة.

Data Quality

- No missing values were found. لم يتم العثور على قيم مفقودة.
- No duplicate rows were found. لم يتم العثور على صفوف مكررة.

Features

- The dataset contains one categorical feature, **Gender**, and several numerical features. وعدة متغيرات رقمية **Gender** تحتوي البيانات على متغير فئوي واحد وهو.

Target

- **Calories Burned** is the regression target. **Calories Burned** هو المتغير المستهدف في نموذج الانحدار.

Important Note

- Correlation measures linear relationships only. الارتباط يقيس العلاقات الخطية فقط.
- Feature importance should therefore not be determined from correlation alone. لذلك لا يجب تحديد أهمية المتغيرات اعتمادًا على الارتباط وحده.

- Machine learning models will be used later to evaluate predictive performance. سيتم استخدام نماذج التعلم الآلي لاحقًا لتقييم القدرة التنبؤية للمتغيرات.

24. Conclusion

الخلاصة

The dataset has been explored from a statistical and structural perspective. We examined numerical and categorical variables, descriptive statistics, target statistics, correlations, group-based analysis, and potential outliers.

تم استكشاف البيانات من الناحية الهيكلية والإحصائية. قمنا بتحليل المتغيرات الرقمية والفئوية والإحصاءات الوصفية وإحصاءات المتغير المستهدف والارتباطات والتحليل حسب المجموعات والقيم الشاذة المحتملة.

The next step is to visualize these relationships and distributions using plots.

الخطوة التالية هي تحويل هذه العلاقات والتوزيعات إلى تصورات بيانية باستخدام الرسومات

```
In [23]: print("=" * 60)
print("01_2 DATA EXPLORATION COMPLETED")
print("اكتمل الاستكشاف والتحليل المتقدم للبيانات")
print("=" * 60)
```

```
=====
01_2 DATA EXPLORATION COMPLETED
اكتمل الاستكشاف والتحليل المتقدم للبيانات
=====
```